인공지능 기초 2주차: 머신러닝 개요

강의 목표
- 지도 학습과 비지도 학습을 구분한다.
- 과적합의 원인과 대책을 설명한다.
- 모델 평가 지표를 계산한다.

머신러닝의 종류

지도 학습(supervised learning)은 입력과 정답 레이블이 있는 데이터로 학습한다. 분류와 회귀가 대표적이다. 비지도 학습(unsupervised learning)은 레이블 없이 데이터의 구조를 찾으며 군집화와 차원 축소가 있다. 강화 학습(reinforcement learning)은 에이전트가 환경과 상호작용하며 보상을 최대화하는 정책을 학습한다.

선형 회귀와 경사 하강법

선형 회귀는 y = wx + b 형태의 직선으로 입력과 출력의 관계를 모델링한다. 손실 함수로 평균 제곱 오차(MSE)를 사용한다.

경사 하강법(gradient descent)은 손실 함수의 기울기 반대 방향으로 가중치를 조금씩 갱신한다. 갱신 크기를 정하는 값을 학습률(learning rate)이라 한다. 학습률이 너무 크면 발산하고, 너무 작으면 수렴이 느리다.

$$w = w - \eta * \partial L / \partial w$$

과적합과 일반화

과적합(overfitting)은 모델이 학습 데이터의 잡음까지 외워 새로운 데이터에서 성능이 떨어지는 현상이다. 학습 오차는 작지만 검증 오차가 크면 과적합을 의심한다.

대책: 더 많은 데이터 수집, 규제(L1, L2 정규화), 드롭아웃, 조기 종료(early stopping), 교차 검증, 모델 단순화.

과소적합(underfitting)은 모델이 너무 단순해 학습 데이터조차 잘 설명하지 못하는 상태다.

데이터 분할과 교차 검증

데이터는 보통 학습용, 검증용, 테스트용으로 나눈다. 검증 세트로 하이퍼파라미터를 고르고, 테스트 세트는 마지막 성능 보고에만 한 번 사용한다.

k-겹 교차 검증(k-fold cross validation)은 데이터를 k개로 나누어 k번 학습과 검증을 반복하고 평균 성능을 쓴다. 데이터가 적을 때 유용하다.

분류 모델의 평가 지표

혼동 행렬(confusion matrix)은 TP, FP, FN, TN으로 예측 결과를 정리한다.
정확도(accuracy) = (TP + TN) / 전체
정밀도(precision) = TP / (TP + FP)
재현율(recall) = TP / (TP + FN)
F1 점수 = 2 × 정밀도 × 재현율 / (정밀도 + 재현율)

클래스가 불균형하면 정확도만으로는 성능을 판단하기 어렵다. 예를 들어 양성이 1%인 데이터에서 모두 음성으로 예측해도 정확도는 99%다.

의사결정나무와 앙상블

의사결정나무는 특성 값에 따라 데이터를 반복해서 나누는 모델로 해석이 쉽다. 분할 기준으로 지니 불순도나 엔트로피(정보 이득)를 사용한다. 깊이가 깊어지면 과적합되기 쉽다.

랜덤 포레스트는 부트스트랩 샘플과 무작위 특성 선택으로 여러 나무를 만들어 투표하는 배깅(bagging) 방식이다. 그래디언트 부스팅은 이전 모델의 오차를 다음 모델이 보완하도록 순차적으로 학습한다.

신경망과 활성화 함수

인공 신경망은 입력층, 은닉층, 출력층으로 구성된다. 각 뉴런은 가중합에 활성화 함수를 적용한다. 시그모이드는 출력을 0과 1 사이로 만들지만 깊은 망에서 기울기 소실(vanishing gradient)이 생긴다. ReLU는 max(0, x)로 계산이 간단하고 기울기 소실을 줄여 가장 널리 쓰인다. 다중 분류의 출력층에는 소프트맥스를 쓴다.

역전파(backpropagation)는 연쇄 법칙으로 출력 오차를 각 가중치의 기울기로 전달하는 알고리즘이다.

군집화: k-평균

k-평균(k-means)은 데이터를 k개의 군집으로 나누는 비지도 학습 알고리즘이다.
1. k개의 중심을 임의로 정한다.
2. 각 데이터를 가장 가까운 중심에 배정한다.
3. 각 군집의 평균으로 중심을 옮긴다.
4. 중심이 변하지 않을 때까지 2~3을 반복한다.

k 값은 엘보 방법(elbow method)이나 실루엣 계수로 정한다. 초기 중심에 따라 결과가 달라지므로 k-means++ 초기화를 많이 쓴다.